

메인 프로젝트

# 딥러닝 기반 복부, 흉부 CT 영상 해상도 향상 및 분류 모델 연구

D조

김단 김지원 심세윤

# Contents 목차

## 01 | 프로젝트 개요

- 주제 배경

## 02 | 선행 연구

## 03 | 데이터 개요

## 04 | 해상도 향상

- GAN-CIRCLE


## 05 | 폐암 분류 모델

- DenseNet

## 06 | 결과

# Background 주제 선정 배경

## 1 주제 배경



### ● CT란?

X선(방사선) 촬영 기법으로 얻은 인체 내부의 투영 데이터를 컴퓨터로 재구성하여 단층 영상을 만들어 내는 기술

- 인체에 X선(방사선)을 투과시켜 영상을 획득

⇒ 多 방사선을 인체에 피폭시킴.

- 복부, 흉부 CT: 10 ~ 25mSv

## 2 문제 상황

- 질병관리청 2023년 국민 의료방사선 이용현황: 2022년 대비 13% 증가 연간 4억 건 → CT 촬영 피폭선량이 전체의 67.3%
- CT 영상은 몸 주위 여러 각도에서 많은 X선 이미지를 캡처 후, 컴퓨터에 의해 3D 이미지로 재구성함  
⇒ 이 과정에서 noise(잡음)나 artifact(허상)은 피할 수 없는 문제
- 방사선 노출위험: 국제방사선방호위원회기준 5년간 총 누적선량 100mSv 이하, 연간 20mSv 이하  
⇒ CT 2~3번만 찍어도 연간 기준을 넘음(흉부 기준)
- 김종호 서울대병원 영상의학과 교수 曰 “비록 의료용이지만 CT 방사선은 저감 노력을 기울여야 한다.”

## Topic 주제

“

딥러닝 기반 복부, 흉부 CT 영상 해상도 향상 및 분류 모델 연구

”

### GAN 모델 연구

- 초저선량으로도 선명한 CT 영상을 획득할 수 있도록 하여, CT 환자가 방사능 피폭 위험에 덜 노출될 수 있도록 하는 모델을 개발하고자 함

### DenseNet 모델 연구

- 복부 및 흉부 CT 영상 분류 모델을 개발, 의료진들이 모델을 활용하여 더 쉽게 복부 흉부 관련 질병에 대한 분류를 할 수 있도록 하고자 함

# 선행 연구

## Development of an Optimized Deep Learning Model for Medical Imaging

- 의료 영상 분야에서의 딥러닝 모델을 개발하는 과정에서 각 단계별 고려해야 할 중요 요소들과 이를 위한 최적화 방법을 살펴봄
- 딥러닝의 목적과 데이터의 규모, 사용하는 영상의 특성 등을 우선적으로 고려하고, 이에 필요한 최적화 방법들을 적절하게 사용해야함을 강조

## The Latest Trends in the Use of Deep Learning in Radiology

- 의료 영상에서의 최신 딥러닝 알고리즘 적용 사례를 분석
- 현재까지 의료영상분야에서 개발된 여러 딥러닝 알고리즘은 진단기구보다는 의사결정 지원시스템에 가까운 단계임을 보임

## 어텐션 기법 및 의료 영상에의 적용에 관한 최신 동향

- 어텐션 메커니즘을 적용하여 CT 데이터의 노이즈 제거 및 고해상도 복원 기술의 활용 방안을 분석
- 의료 영상의 질적 향상 및 잡음 제거에 딥러닝의 역할을 강조

# 선행 연구


## 기존 연구의 한계

- 대부분이 고해상도 복원 또는 노이즈 제거를 개별적으로 다루고 있음
- 분류 성능 향상 및 일반화는 다루지만 모델의 실제 의료 활용성 측면에서 부족

## 연구 목적

- 다양한 모델을 결합하여 데이터 해상도 개선과 함께 분류 모델을 동시에 개발
- LDCT 데이터를 FDCT로 변환함으로써 방사선 노출을 줄이면서도 의료 영상의 품질을 유지하기 위한 데이터 구축
- 저선량 CT 데이터 기반으로 암 분류 및 예측의 성능을 개선할 가능성을 열고자 함

# 데이터 개요



## Notation

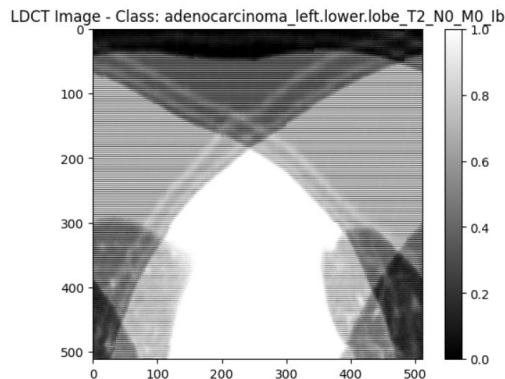
의료 영상이나 3D 데이터를  
사용하려 했으나, 메모리 등  
기기 문제로 2D 이미지로 대체

## Chest CT-Scan images Dataset

- 흉부 CT 이미지 데이터셋
- 클래스는 총 4가지로 분류됨: adenocarcinoma, large cell carcinoma, normal, squamous cell carcinoma

## 전처리

- 각 이미지별 크기 확인 후 이미지를 512x512 픽셀로 리사이즈
- 모든 이미지는 텐서로 변환



## FDCT 데이터를 LDCT 데이터로 변환

- FDCT 이미지를 12비트 포맷으로 변환 후, 푸아송 노이즈를 추가하여 LDCT 데이터 생성
- 노이즈 강도 = 방사선 감소 계수(0.25)

# 모델 GAN-CIRCLE




Fig. 4. Generator structure of GAN-CIRCLE.




Fig. 5. Discriminator structure of GAN-CIRCLE.

## GAN-CIRCLE

- **GAN-CIRCLE** 사용 이유: CycleGAN, IdentityGAN, GAN-CIRCLE / DSVD, BM3D(기존 노이즈 제거 방법) 중 가장 높은 노이즈 제거 성능 & 빠른 계산 속도를 보임
- FDCT, LDCT 일치 안해도 노이즈 제거 가능하며 환자 데이터 정렬 / mapping 없어도 대규모 데이터셋 활용 가능
- 지도학습인 RED-CNN과 비교해서 비슷한 성능을 보이는 비지도 학습 모델

## 결과

Epoch 50, Gen\_G\_Loss: 0.27977654337882996

Gen\_F\_Loss: 0.10848736763000488

Disc\_X\_Loss: 9.444415627513081e-05


Disc\_Y\_Loss: 0.0001263518788618967

Average PSNR: 12.081498624381538

Average SSIM: 0.29404970927902463




# 모델 DenseNet



## DenseNet

- 각 층의 출력을 이후 모든 층의 입력으로 직접 연결하여 특성 재사용하는 CNN
- 의료 이미지 분류 문제에 자주 사용
- 가장 경량화된 모델인 densenet-121 사용

## 모델 DenseNet



Dense block : 이전 레이어의 출력 + 새로운 특징 학습

Transition layer : 채널 수 감소 + 공간 크기 축소, 특성을 압축하여 전달 => 계산 비용 감소, 과적합 방지

Initial conv -> Dense Block 1 -> Transition Layer 1 -> Dense Block 2 -> Transition Layer 2 ->  
Dense Block 3 -> Transition Layer 3 -> Dense Block 4 -> Fully Connected

## 학습 과정


캐글 고선량 데이터로 DenseNet121 학습한 후 캐글 고선량 test data로 성능 체크 (base model)

캐글 고선량 test data에 포아송 노이즈 추가 (low dose ct data)

이 데이터로 학습된 DenseNet 모델 (base model) 성능 체크



[원본]



[포아송 노이즈 추가]

## 학습 과정

- low dose ct data를 Cycle gan으로 포아송 노이즈 제거
- 이 데이터로 학습된 DenseNet 모델 성능 체크
- base model을 고선량 데이터로만 학습한 이유
  - 노이즈 제거 효과를 명확히 파악
  - 현실에는 저선량 CT 데이터보다 고선량 CT 데이터가 많음 => 고선량 CT 데이터 위주로 학습하더라도 좋은 성능을 갖게 하기 위함

# Conclusion

## 기대 효과

---

- 초저선량으로도 CT 영상의 잡음을 줄이고, 선명한 이미지를 얻게 함  
→ 환자에게 가해지는 방사선 노출 최소화 + 환자에 대한 정확한 진단, 치료 계획이 가능하게 될 것임
  - 복부, 흉부 CT 기기 발전에 기여
-

# Conclusion

한계

---

- DenseNet121, ResNet18 모델 아키텍처를 수정하여 성능 향상을 시도 -> 성능 하락
-